
Scouting LATAM: Jugadores Subvalorados con Datos

Propuesta Analítica — PC1

AD3010 Business Analytics

Universidad de Ingeniería y Tecnología — UTEC
Administración & Negocios Digitales

Profesor: Alan Morante

Integrante	Código
Frances Forsyth	202320199
Fatima Marquez	202210592
Rafael Alcandré	202210012

Semana 6 · 2026

Índice

1. Definición del Problema de Negocio	2
2. Preguntas Analíticas	2
3. Datasets y Fuentes	2
3.1. Dataset Base — FIFA 23/24 (Kaggle)	2
3.2. Dataset Enriquecedor — Transfermarkt (GitHub público)	3
3.3. Dataset de Contexto — World Bank GDP per cápita	3
4. Estrategia de Enriquecimiento	3
4.1. Justificación	3
4.2. Pregunta que solo puede responderse con el enriquecimiento	4
4.3. Mecanismo de cruce	4
5. Análisis Exploratorio de Datos (EDA)	4
5.1. Distribución del Overall por País	5
5.2. Valor FIFA vs. Valor Real de Mercado	6
5.3. Brecha de Valoración por Posición	7
5.4. Jóvenes con Mayor Techo de Crecimiento	8
5.5. Perfil de Habilidades: Perú vs. LATAM	9
5.6. GDP per cápita vs. Calidad de Jugadores por País	10
6. KPIs del Proyecto	11
7. Plan de Trabajo — Fase 2	12
7.1. Riesgos identificados	12
8. Conclusiones del EDA	13

1. Definición del Problema de Negocio

Un fondo de inversión deportiva evalúa adquirir participaciones en clubes de la Liga 1 peruana. Para tomar esa decisión necesita responder una pregunta concreta: **¿qué jugadores latinoamericanos tienen atributos superiores a su valor de mercado actual, y cuál es el ROI esperado por posición?**

El mercado futbolístico presenta ineficiencias sistemáticas: jugadores con alto rendimiento objetivo permanecen subvalorados por factores de visibilidad, liga de origen o país de procedencia. Identificar esas ineficiencias antes que el mercado las corrija es el núcleo de la propuesta analítica.

El cliente necesita, al final del proyecto, una lista accionable de jugadores con precio actual, precio justo estimado y brecha porcentual por posición, que le permita priorizar adquisiciones con el mejor balance riesgo-retorno.

2. Preguntas Analíticas

- P1. Subvaloración global:** ¿Qué jugadores LATAM tienen atributos FIFA elevados pero valor de mercado real (Transfermarkt) significativamente menor al esperado para su perfil?
- P2. Análisis por posición:** ¿En qué posiciones es mayor la brecha entre el valor FIFA y el valor de mercado? ¿Dónde está el mejor ROI por unidad de inversión?
- P3. Proyección de crecimiento:** ¿Qué jugadores menores de 23 años tienen el mayor margen de crecimiento (potencial – overall), y cuál sería su precio proyectado al alcanzar ese techo?
- P4. Caso Perú:** ¿Los jugadores peruanos con atributos similares a pares regionales tienen precios de mercado menores? ¿Existe un descuento sistemático explicado por el mercado y no por el talento?

3. Datasets y Fuentes

3.1. Dataset Base — FIFA 23/24 (Kaggle)

El dataset *FIFA 23/24 Complete Player Dataset* contiene más de 180,000 registros de jugadores con más de 100 atributos cada uno. Para este proyecto se utilizó exclusivamente **FIFA 24** (la versión más reciente disponible), filtrando por nacionalidad latinoamericana.

Cuadro 1: Características del dataset base FIFA 24 — LATAM

Característica	Valor
Jugadores de campo LATAM (FIFA 24)	2,982
Jugadores peruanos	122
Overall mediano LATAM	68
Overall mediano Perú	67
Valor mediano FIFA (LATAM)	€1.4M
Edad promedio	26.1 años
Atributos de habilidad disponibles	pace, shooting, passing, dribbling, defending, physic

Variables clave: `overall`, `potential`, `value_eur`, `age`, `nationality_name`, `player_positions`, y las seis estadísticas base de campo.

3.2. Dataset Enriquecedor — Transfermarkt (GitHub público)

Contiene el valor de mercado real de jugadores según reportes de Transfermarkt, una de las referencias más utilizadas por clubes y fondos de inversión deportiva. Su relevancia para este proyecto es crítica: **FIFA asigna valores estimados; Transfermarkt registra el precio que el mercado está dispuesto a pagar.**

Cuadro 2: Características del dataset Transfermarkt — LATAM

Archivo	Descripción
<code>players.csv</code>	Perfil del jugador, valor actual y máximo histórico
<code>player_valuations.csv</code>	Historial de valoraciones por fecha
Jugadores LATAM disponibles	7,310
Variable de cruce	Nombre del jugador (normalizado)

3.3. Dataset de Contexto — World Bank GDP per cápita

GDP per cápita en USD para el año 2023, descargado de data.worldbank.org. Se utiliza para controlar el efecto del contexto económico del país de origen sobre el precio de mercado de sus jugadores, evitando confundir “jugador barato por su economía” con “jugador barato por falta de visibilidad”.

4. Estrategia de Enriquecimiento

4.1. Justificación

El dataset base de FIFA provee atributos de habilidad robustos, pero no contiene el precio de mercado real. Sin ese precio, el análisis de subvaloración es imposible: solo

tendríamos un ranking de habilidades, no una herramienta de inversión.

El cruce con Transfermarkt aporta la variable **precio real de mercado** (`market_value_in_eur`), que permite calcular:

$$\text{Brecha} = \text{Valor FIFA} - \text{Valor Transfermarkt}$$

$$\text{Ratio} = \frac{\text{Valor FIFA}}{\text{Valor Transfermarkt}}$$

Un ratio > 1 indica que FIFA valora al jugador más alto que el mercado: potencial candidato subvalorado.

4.2. Pregunta que solo puede responderse con el enriquecimiento

La Pregunta 1 completa —identificar subvalorados— depende exclusivamente del cruce con Transfermarkt. **Sin el precio real, no existe análisis de inversión.** El dataset FIFA por sí solo no permite distinguir entre un jugador bueno y un jugador bueno y barato.

4.3. Mecanismo de cruce

El join entre FIFA y Transfermarkt se realiza por nombre de jugador (campo `short_name` en FIFA, campo `name` en Transfermarkt), normalizando a minúsculas y eliminando espacios. El GDP del World Bank se cruza por código ISO del país (`country_iso`).

5. Análisis Exploratorio de Datos (EDA)

5.1. Distribución del Overall por País




Figura 1: Distribución del rating overall por país de origen (FIFA 24, LATAM). La línea punteada indica la mediana regional. Perú aparece resaltado en rojo.

Argentina y Uruguay concentran los valores medianos más altos de la región, reflejando sus tradiciones de formación futbolística. Brasil lidera en volumen y presenta la mayor dispersión, con más outliers en los extremos superiores. **Perú se ubica con una mediana de 67, un punto por debajo de la mediana regional de 68** — una diferencia estadísticamente marginal que no justifica por sí sola un descuento de precio. Esta observación es el punto de partida de la hipótesis central del proyecto.

5.2. Valor FIFA vs. Valor Real de Mercado




Figura 2: Comparación entre el valor estimado por FIFA 24 y el valor real de Transfermarkt (escala logarítmica). Los puntos sobre la diagonal son jugadores que el mercado subprecia respecto al rating FIFA. Los nombres en rojo corresponden a los cinco con mayor brecha relativa.

La correlación entre valor FIFA y valor Transfermarkt es moderada ($r = 0,574$), lo que confirma que **el rating FIFA no explica completamente el precio de mercado**. Existe un subconjunto de jugadores sistemáticamente por encima de la diagonal: el mercado los subvalora respecto a lo que sus atributos objetivos justificarían. Esos son los candidatos de interés para el fondo inversor.

5.3. Brecha de Valoración por Posición




Figura 3: Ratio mediano entre valor FIFA y valor Transfermarkt por posición (ratio > 1 indica que el mercado subvalora respecto a FIFA).

El análisis por posición revela patrones diferenciados de subvaloración. Las posiciones con ratio mayor a 1x representan las oportunidades de mayor ROI potencial por unidad de inversión. Este hallazgo orienta la estrategia de adquisición del fondo: no todas las posiciones ofrecen el mismo margen de arbitraje, y la asignación de capital debe reflejarlo.

5.4. Jóvenes con Mayor Techo de Crecimiento




Figura 4: Top 10 jugadores LATAM menores de 23 años con mayor margen de crecimiento (potencial – overall). El margen máximo observado es de 22 puntos.

Se identificaron **1,015 jugadores menores de 23 años con potencial superior a su overall actual**. Los diez con mayor margen representan la estrategia de inversión de mayor horizonte temporal: se adquieren con el precio de su nivel actual y se monetizan cuando el mercado reconoce su desarrollo. El margen máximo observado es de 22 puntos, equivalente a pasar de un perfil de liga local a un perfil de liga europea de primer nivel.

5.5. Perfil de Habilidades: Perú vs. LATAM




Figura 5: Radar de habilidades promedio de jugadores peruanos versus el promedio del resto de LATAM (FIFA 24). Los perfiles son prácticamente idénticos en las seis dimensiones evaluadas.

El radar de habilidades es el hallazgo más relevante del EDA para la hipótesis del proyecto: **los jugadores peruanos presentan un perfil de habilidades casi idéntico al promedio regional** en las seis dimensiones de análisis. Si los precios de mercado son menores para los peruanos con el mismo perfil, esa diferencia no se explica por talento sino por el mercado. Verificar esto estadísticamente es el objetivo principal de la regresión en Fase 2.

5.6. GDP per cápita vs. Calidad de Jugadores por País




Figura 6: Relación entre GDP per cápita 2023 (World Bank) y el overall mediano FIFA 24 por país. El tamaño de la burbuja refleja la cantidad de jugadores disponibles en el dataset.

La relación entre el nivel económico del país de origen y la calidad de sus jugadores es débil a moderada en LATAM. Esto indica que el talento futbolístico en la región está distribuido de forma relativamente independiente del PIB nacional. Para el modelo de Fase 2, el GDP se utilizará como variable de control —no como predictor principal— para aislar el efecto económico del efecto de visibilidad en los precios de mercado.

6. KPIs del Proyecto

Cuadro 3: KPIs por pregunta analítica

Pregunta	KPI	Meta
P1. Subvaloración global	Número de jugadores con ratio FIFA/TM $> 1,3x$	Identificar top 20 candidatos
P2. Análisis por posición	Ratio mediano por posición y brecha en euros	Ranking de las 3 posiciones con mayor margen
P3. Proyección de crecimiento	R^2 del modelo de predicción de precio futuro	$R^2 \geq 0,55$
P4. Caso Perú	Coefficiente de variable “es peruano” en regresión de precio	Coefficiente negativo y significativo ($p < 0,05$)

7. Plan de Trabajo — Fase 2

Cuadro 4: Plan de ejecución Fase 2 (semanas 7–14)

Semanas	Actividad	Responsable
7–8	Regresión lineal: predecir valor de mercado desde atributos FIFA. Interpretación de coeficientes en euros por punto de habilidad. Métricas: R^2 , RMSE.	[Frances Forsyth]
9–10	Análisis de series de tiempo sobre historial de valoraciones Transfermarkt. Identificar jugadores con tendencia alcista sostenida.	[Rafael Alcandré]
11–12	Clustering (k-means): segmentar jugadores en perfiles de inversión (gangas, apuestas a futuro, sobrevalorados). Nombrar cada segmento con criterio de negocio.	[Fatima Marquez]
13	Dashboard Power BI interactivo con filtros por posición, país y perfil de riesgo. Narrativa: problema → datos → insight → recomendación.	Todos
14	Presentación ejecutiva final (PC2). Informe escrito. Entrega de lista corta de adquisiciones con precio sugerido por jugador.	Todos

7.1. Riesgos identificados

- R1. Match rate FIFA–Transfermarkt:** El cruce por nombre cubre aproximadamente el 17 % de los jugadores del dataset FIFA. En Fase 2 se mejorará el match incorporando fecha de nacimiento y club actual como variables adicionales de verificación.
- R2. Representatividad de Perú:** Con 122 jugadores de campo, el análisis por subgrupos (posición + edad) puede llegar a muestras pequeñas. Se aplicará el criterio de mínimo 30 observaciones por subgrupo para cualquier conclusión estadística.

8. Conclusiones del EDA

El análisis exploratorio confirma la viabilidad de la propuesta. Existen ineficiencias medibles entre el valor FIFA y el valor de mercado real en jugadores latinoamericanos, con variación sistemática por posición. El perfil de habilidades de los jugadores peruanos es comparable al promedio regional, lo que sustenta la hipótesis de subvaloración por mercado.

Los modelos de Fase 2 —regresión, series de tiempo y clustering— tienen base empírica clara en los datos explorados. El entregable final será una lista accionable de adquisiciones con ROI estimado por posición, que el fondo podrá utilizar directamente en su proceso de decisión.

Repositorio del proyecto: [Repositorio del proyecto](#)

Notebook Colab: [Abrir en Colab](#)